Universidad Nacional Autónoma de México
Facultad de Ingeniería
Inteligencia Artificial

Tarea #3 : Normalización, Rostros de Chernoff y Clasificación con KNN (Diabetes)

Alumno: Vera Morales Juan Pablo
Grupo: 10
Profesor : Romero de la Cruz Alejandro

Introducción

El siguiente reporte comprende la realización de normalización, rostros de Chernoff, relaciones gráficas por paraes de características , entrenamiento y evaluación KNN para distintos valores de K, interpretación y finalmente conclusiones para ambos.

Herramientas

Para la realización de la tarea se utilizó el lenguaje Python y el editor de código Visual Studio Code.

Desarrollo

1. Preparación de datos

Para normalizar los datos se decidió utilizar el método de estandarizacion utilizando la fórmula propuesta:

normalizar.py > ...

```python
import pandas as pd

datos = pd.read_csv("diabetes.csv")

columnas_num = [
    'Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness',
    'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age'
]

datos[columnas_num] = (datos[columnas_num] - datos[columnas_num].mean()) / datos[columnas_num].std()

print(datos[columnas_num].agg(['mean', 'std']).round(2))
```

En un inicio escogí Min-Max pero tras generar un csv para verificar el estado de los datos normalizados noté que a todos los valores de insulina les costaba mucho superar el rango de 0.25 - 0.3 , esto se debia a un gran pico de 850 en esta columna cuando el resto de valores oscilaban un rango de 0 - 300, este pico ocasionaba un gran aplastamiento de los datos y a la hora de generar los rostros seria muy costoso diferenciar uno de 40 de insulina a uno de 120, siendo esta una diferencia del triple y sin embargo pasaria desapercibida por el aplastamiento del valor maximo, por esto se cambio a estandarización.

2. Construcción de rostros de Chernoff

Se mapearon los atributos de la siguiente forma:

Dato Medico	Atributo Físico	Interpretación
Edad	Alto de la cara	+ edad + grande
BMI	Ancho de la cara	+ BMI + ancha
Glucosa	Curvatura de la boca	alta = triste , baja = feliz
Insulina	Ancho de la boca	+ alta + ancha
Presion sanguinea	Ángulo de las cejas	+ alta cejas enojadas, - alta cejas relajadas
Grosor de la piel	Tamaño de la nariz	+ gruesa + grande
Funcion Pedigree Diabetes	Tamaño de los ojos	+ carga genética + grandes
Embarazos	Altura de los ojos	+ arriba + embarazos

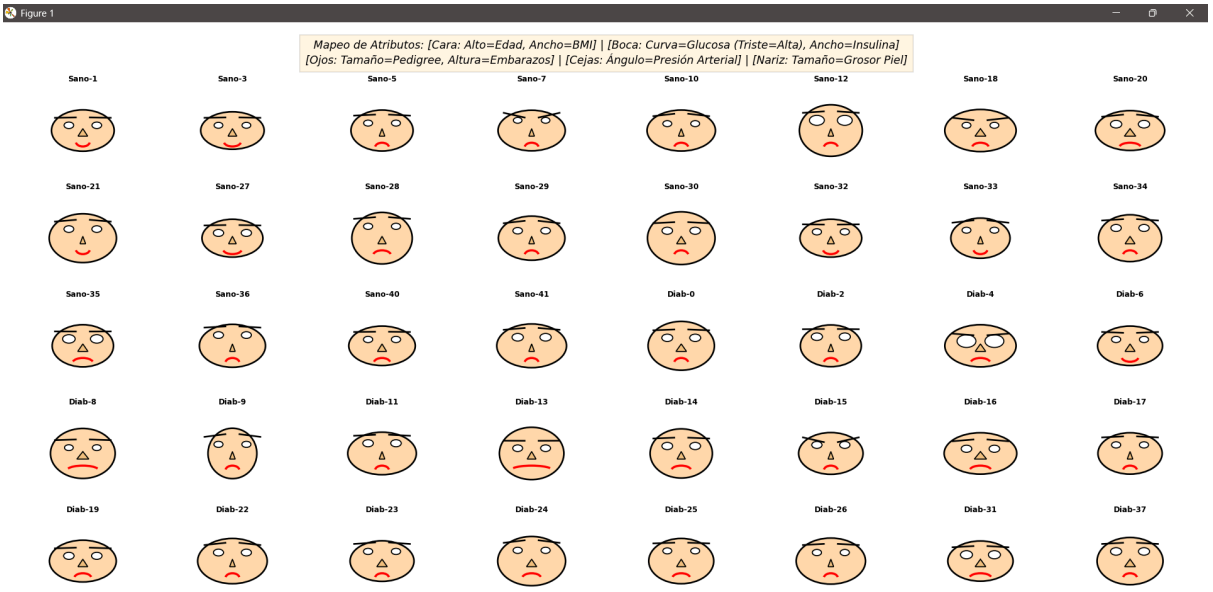

a) Características y combinaciones

De la población con diabetes lo primero que salta a la vista es que todas las bocas tienden a ser tristes significando un alto nivel de glucosa, también el ancho parece mayor, de la misma manera el ángulo de las cejas tiende más al de preocupación, es decir, alta presión sanguínea , finalmente me pareció curioso que (al menos para esta iteración) muchas caras tenían los ojos posicionados mas arriba ,

puede ser solo una coincidencia pero me hace pensar si hay alguna correlación entre el embarazo y la diabetes.

De la población sana la mayoria cuenta con la combinacion boca chica y feliz osea baja insulina baja glucosa, sin embargo tambien se podian ver muchas cejas en el angulo de la presion alta.

Por último me resultó curioso de las dos poblaciones que ninguna contaba con un gran grupo de personas con ojos grandes, estando casi todas en el mismo rango, lo que me hace pensar que la propensión era casi la misma para todos con algunas excepciones.

b) ¿Es fácil distinguirlos?

Relativamente, se vuelve fácil cuando los tienes divididos en dos grupos sabiendo que uno de los dos es el sano y otro el de diabetes, pero a la hora de intentar decidir si una cara en particular tiene diabetes se vuelve complicado, los dos factores que más llegan a resaltar son la forma y longitud de la sonrisa que es una combinación común en el grupo de diabetes aunque también tienen relativa presencia en el grupo de personas sanas, otro atributo que resalta puede ser el ancho de la cara, mezclado con los anteriores se tienen mayor certeza sobre el grupo al que pertenece.

c) ¿Qué limitaciones viste?

Las mayores limitaciones las noté en los atributos que no resaltan particularmente en un grupo u otro o no le encuentro una correlación particular con la diabetes, por ejemplo, no encontré ningún patrón con la nariz que denota el grosor de la piel y podría asegurar que es una distribución uniforme entre un grupo u otro, los ojos me parecieron otro atributo repartido de forma bastante equitativa con los diabeticos con una pequeña tendencia a que fueran mas grandes pero de nuevo, no aseguraban nada, finalmente el embarazo reflejado en la altura de los ojos es otro atributo que encontre repartido de manera equitativa y no encontre como correlacionar con otros factores para intentar determinar si una cara tenia diabetes.

3. Gráficas por pares de características

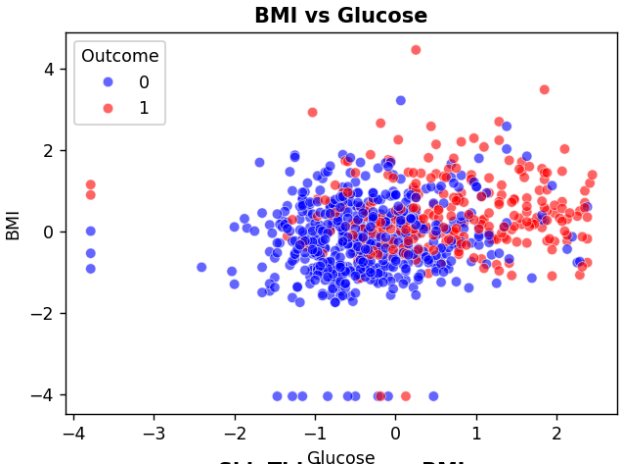

En esta primera gráfica BMI contra glucosa podemos ver varias cosas, primero independientemente del lugar dentro del BMI en el que se encuentren los pacientes diabéticos tienden a estar del lado de la glucosa alta, además vemos una gran masa de sanos en las posiciones 0 de BMI y 0 de glucosa mientras que la línea de diabéticos está desplazada hacia arriba y la izquierda.

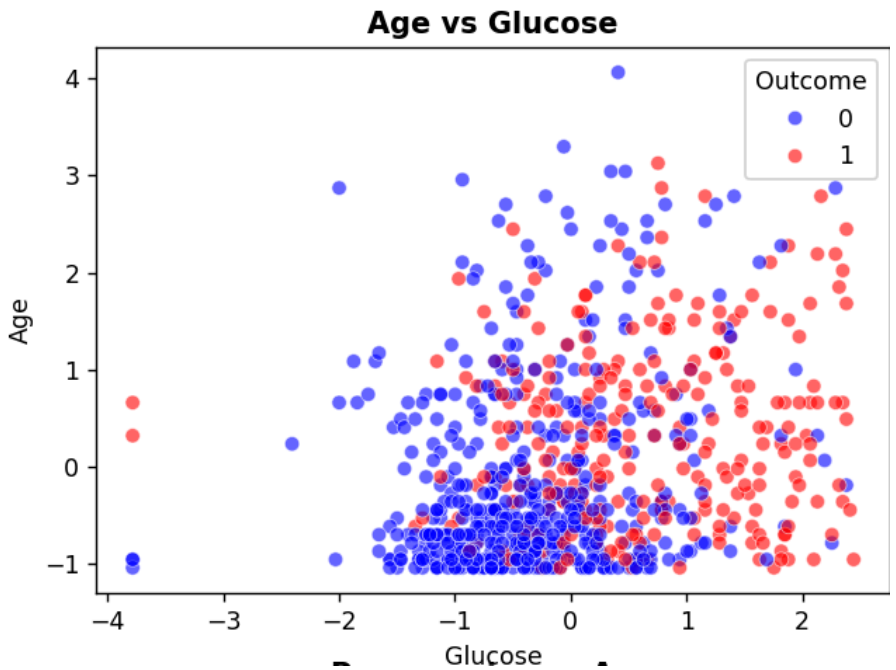

En esta segunda gráfica edad vs glucosa la interpretación del lado de la glucosa es la misma , sin embargo ahora nuestra característica destacada es la mayor presencia de personas de alta edad que no tienen diabetes quiza reflejando el recorte en longevidad que produce esta enfermedad.

Esta tercera gráfica en la que de nuevo tenemos a la glucosa y la pareamos con la insulina vemos como aunque pudiéramos pensar que es un factor muy determinante, podríamos decir que existen las mismas ocurrencias para la insulina para sanos y diabéticos.

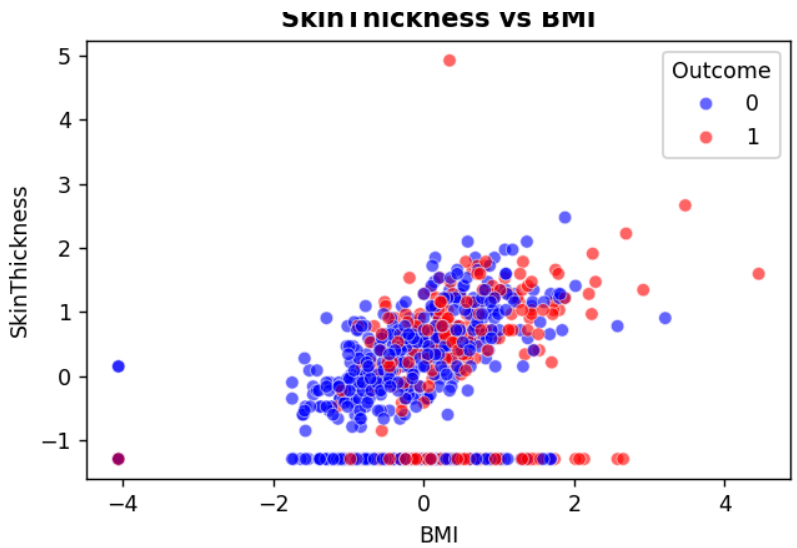

En la siguiente gráfica escogí datos de los cuales no encontrara una correlación como tal o un entendimiento de porque podrian afectar a la propencidad a diabetes (en el caso del grosor de la piel) , esta es la primera casi completa superposicion entre los valores de ambos grupos.

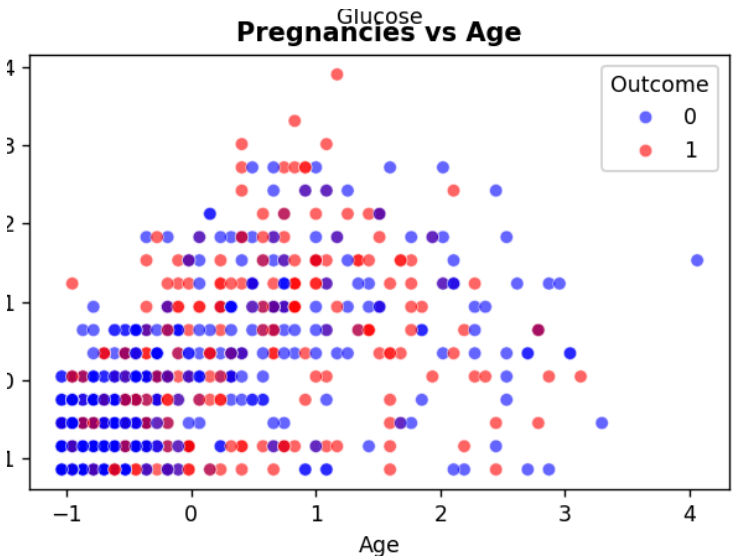

La quinta tabla muestra patrones curiosos entre la edad y la cantidad de embarazos, no hay una correlación particular, y ambos presentan zonas de concentración frente al otro.

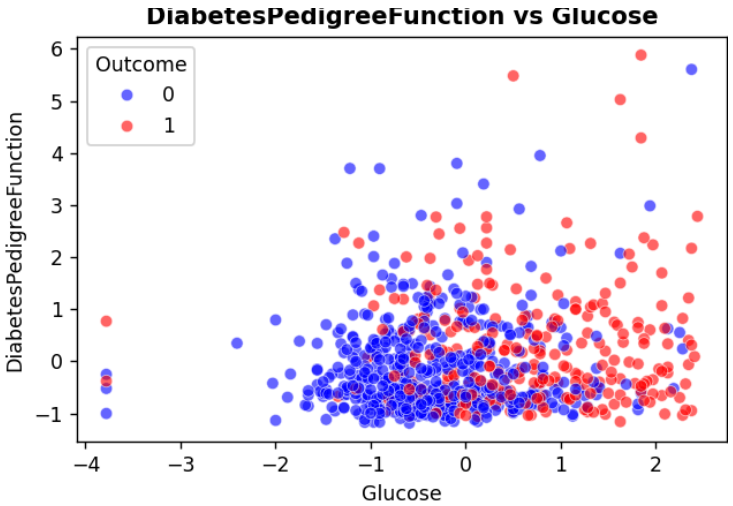

En esta última tabla utilizando la función de carga genética me pareció curioso confirmar lo que observé en rostros de Chercoff sobre esta misma, no parece haber una particular tendencia menor de los pacientes sanos , los valores son muy parecidos a los de aquellos con diabetes, cosa que se reflejaba en el similar tamaño de ojos de ambos grupos.

4. KNN con partición 70 / 30

¿Qué es una matriz de confusión?

Una matriz de confusión es un método para visualizar los resultados de un algoritmo y sirve para evaluar el rendimiento del mismo comparando valores previos con valores reales del conjunto de datos.

- TP (verdaderos positivos): predije diabetes y sí era diabetes.
- TN (verdaderos negativos): predije no diabetes y sí era no diabetes.
- FP (falsos positivos): predije diabetes, pero no era diabetes.
- FN (falsos negativos): predije no diabetes, pero era diabetes.

	Pred: Diabetes	Pred: No diabetes
Real: Diabetes	TP	FN
Real: No diabetes	FP	TN

Euclidiana

```
[Running] python -u "c:\Users\Lenovo\OneDrive\Escritorio\IA 2026-2\Tarea 3\particion.py"

========================================
--- Evaluando Distancia: EUCLIDIANA ---
========================================

[ K = 3 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             100          15
Real: Diab                 73          42

[ K = 5 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             101          14
Real: Diab                 74          41

[ K = 7 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             107           8
Real: Diab                 80          35

[ K = 11 | Accuracy = 0.6304 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             109           6
Real: Diab                 79          36

[ K = 13 | Accuracy = 0.6348 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             110           5
Real: Diab                 79          36

[ K = 15 | Accuracy = 0.6261 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             109           6
Real: Diab                 80          35
```

Vemos resultados iguales para 3, 5, 7 aumentando solo hasta k = 11 y nuestro mejor resultado en k = 13 seguido de un bajon en k = 15 significando que no solo basta con dar un valor de K alto para conseguir una buena precisión.

Manhattan

```
========================================
--- Evaluando Distancia: MANHATTAN ---
========================================

[ K = 3 | Accuracy = 0.6261 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             103          12
Real: Diab                 74          41

[ K = 5 | Accuracy = 0.6000 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             101          14
Real: Diab                 78          37

[ K = 7 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             108           7
Real: Diab                 81          34

[ K = 11 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             106           9
Real: Diab                 79          36

[ K = 13 | Accuracy = 0.6000 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             108           7
Real: Diab                 85          30

[ K = 15 | Accuracy = 0.6087 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             109           6
Real: Diab                 84          31
```

Para distancia Manhattan la mejor variante se encontró en la primera de las K, aquí vemos que de igual forma puede que ciertos algoritmos se vean afectados instantáneamente por incluir más valores.

Minkowski

```
========================================
--- Evaluando Distancia: MINKOWSKI ---
========================================

[ K = 3 | Accuracy = 0.6261 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             101          14
Real: Diab                 72          43

[ K = 5 | Accuracy = 0.6609 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             107           8
Real: Diab                 70          45

[ K = 7 | Accuracy = 0.6435 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             108           7
Real: Diab                 75          40

[ K = 11 | Accuracy = 0.6217 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             109           6
Real: Diab                 81          34

[ K = 13 | Accuracy = 0.6174 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             108           7
Real: Diab                 81          34

[ K = 15 | Accuracy = 0.6217 ]
                Pred: No Diab  Pred: Diab
Real: No Diab             111           4
Real: Diab                 83          32
```

Utilizamos p = 3 para observar un comportamiento intermedio entre Euclidiana y Chebyshev, el mejor valor de accuracy se encuentra en k = 5, aunque en valores posteriores parece que la accuracy no tiende a caer y puede ir subiendo.

Chebyshev

```
========================================
--- Evaluando Distancia: CHEBYSHEV ---
========================================

[ K = 3 | Accuracy = 0.6174 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            102          13
Real: Diab                75          40

[ K = 5 | Accuracy = 0.6304 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            105          10
Real: Diab                75          40

[ K = 7 | Accuracy = 0.6391 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            107           8
Real: Diab                75          40

[ K = 11 | Accuracy = 0.6087 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            109           6
Real: Diab                84          31

[ K = 13 | Accuracy = 0.6087 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            109           6
Real: Diab                84          31

[ K = 15 | Accuracy = 0.6087 ]
                 Pred: No Diab  Pred: Diab
Real: No Diab            110           5
Real: Diab                85          30
```

Por último Chebyshev presenta su mejor accuracy con el valor de k = 7 , cayendo para valores posteriores.

Tabla de resumen final

Distancia	K	Accuracy
chebyshev	7	0.639130
euclidiana	13	0.634783
manhattan	3	0.626087
minkowski	5	0.660870

5. Conclusiones

En mi opinión, para la cantidad de datos proporcionados, la correlación que les encuentro a los mismos con el problema y la complejidad de KNN me parece que entrega resultados aceptables, para las pruebas que realizamos vemos que el mismo nos da poco más de 60% de accuracy, el mejor rendimiento se encontró en torno a k = 7 lo que indica que un grupo considerable de vecinos suficiente como para capturar los patrones locales pero sin suavizar excesivamente la frontera es lo que mejor funciona, en cuanto a Chernoff fue una representacion de lo mas interesante y si bien ya expuse atras porque creo que conforma una solucion complicada debido al solapamiento de muchos datos en este problema, si te permite ver muy claramente aquellos patrones muy definidos como en mi caso fue la sonrisa triste y la boca ancha, en cuanto a lo que mejoraria creo que, y supongo es de manera voluntaria, el dataset presenta muchos valores que solamente entorpecen el analisis, esto se pude ver en la cantidad de valores completamente pegados a la izquierda y abajo en las graficas, quiza con valores un poco definidos ademas de tomar datos que o bien sean indicadores mas directos de diabetes o conforme una pareja fuerte con otro dato formando una pareja con una alta separacion entre sanos y diabeticos podrian crear soluciones mas precisas.